漫画：什么是KMP算法?

CSDN
发布时间: 20-02-28 07:50 鲲鹏计划获奖作者,CSDN官方账号

作者 | 小灰

来源 | 程序员小灰（ID：chengxuyuanxiaohui）

作者最新文章

官宣！CSDN 发布 C 站软件工程师能力认证

2年600人搭建出“异世界”，这家影视渲染公司如何用云打破常规

联手三年，获数千名客户，阿里云如何重构Elastic开放免费技术?

相关文章

真正的高手，都是“反算法型”的人

科技越进步，人类的智商越倒退?

饿了么算法，骑手背后的吸血鬼

万物皆可有算法

从算法之法到法之算法，激荡算法时代

好的好的，顺便帮我也买两个。

———— 第二天 ————

小灰是吧？请简单介绍一下你自己。

好的！

blah blah blah .....


下面来考考你的算法知识：
你都了解哪些［字符串匹配］
算法？


字符串匹配算法，我了解很多呢！
包括 BF 算法、RK 算法、BM 算法。


那你了解 KMP 算法吗？能不能
写代码实现一下？

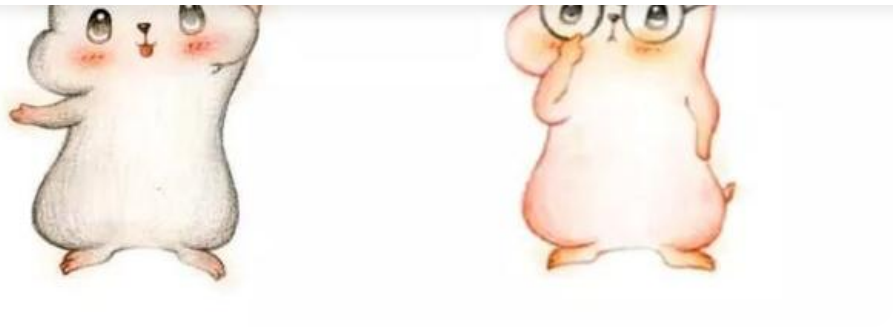

Sorry...

KMP 算法我还不会.....

呵呵，没关系，

回家等通知去吧！

唉.....

大黄，你可不可以给我
讲讲 KMP 算法呀？

前情回顾

在字符串匹配算法的前两讲，我们分别介绍了暴力算法BF算法，利用哈希值进行比较的RK算法，以及尽量减少比较次数的BM算法，没看过的小伙伴可以点击下方链接：

1. BF算法和RK算法

2. BM算法

如果没时间细看也没关系，就让我带着大家简单梳理一下。

首先，给定 “主串” 和 “模式串” 如下：

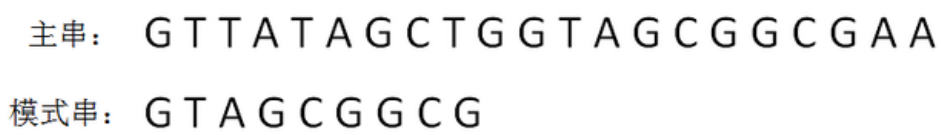

BF算法是如何工作的?

正如同它的全称BruteForce一样，BF算法使用简单粗暴的方式，对主串和模式串进行逐个字符的比较：

第一轮，模式串和主串的第一个等长子串比较，发现第0位字符一致，第1位字符一致，第2位字符不一致：

模式串：G T A G C G G C G

第二轮，模式串向后挪动一位，和主串的第二个等长子串比较，发现第0位字符不一致：

第三轮，模式串继续向后挪动一位，和主串的第三个等长子串比较，发现第0位字符不一致：

以此类推，一直到第N轮：

当模式串挪动到某个合适位置，逐个字符比较，发现每一位字符都是匹配时，比较结束：

BF算法的缺点很明显，效率实在太低了，每一轮只能老老实实地把模式串右移一位，实际上做了很多无谓的比较。

利用BM算法，上面的主串和模式串匹配只需要比较三轮：

主串： G T T A T A G C T G G T A G C G G C G A A

模式串： G T A G C G G C G

主串： G T T A T A G C T G G T A G C G G C G A A

模式串： G T A G C G G C G

主串： G T T A T A G C T G G T A G C G G C G A A

模式串： G T A G C G G C G

有一种算法和 BM 算法十分相似，它的目标也是让模式串在每一轮尽量多移动几位，从而减少无谓的字符比较，这就是著名的 KMP 算法。

KMP 算法由三位计算机科学家 D. E. Knuth、J. H. Morris 和 V. R. Pratt 提出，KMP 这个算法名字正是取自这三个人的姓氏首字母。

KMP算法的整体思路

KMP算法的整体思路是什么样子呢？让我们来看一组例子：

KMP算法和BF算法的“开局”是一样的，同样是把主串和模式串的首位对齐，从左到右对逐个字符进行比较。

第一轮，模式串和主串的第一个等长子串比较，发现前5个字符都是匹配的，第6个字符不匹配，是一个“坏字符”：

这时候，如何有效利用已匹配的前缀 “GTGTG” 呢?

我们可以发现，在前缀“GTGTG”当中，后三个字符“GTG”和前三位字符“GTG”是相同的：

在下一轮的比较时，只有把这两个相同的片段对齐，才有可能出现匹配。这两个字符串片段，分别叫做最长可匹配后缀子串和最长可匹配前缀子串。

第二轮，我们直接把模式串向后移动两位，让两个“GTG”对齐，继续从刚才主串的坏字符A开始进行比较：

显然，主串的字符A仍然是坏字符，这时候的匹配前缀缩短成了GTG：

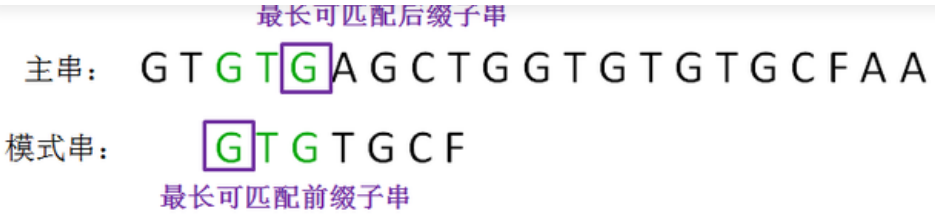

第三轮，我们再次把模式串向后移动两位，让两个“G”对齐，继续从刚才主串的坏字符A开始进行比较：

以上就是KMP算法的整体思路：在已匹配的前缀当中寻找到最长可匹配后缀子串和最长可匹配前缀子串，在下一轮直接把两者对齐，从而实现模式串的快速移动。

next 数组

next数组到底是个什么鬼呢？这是一个一维整型数组，数组的下标代表了“已匹配前缀的下一个位置”，元素的值则是“最长可匹配前缀子串的下一个位置”。

或许这样的描述有些晦涩，我们来看一下图：

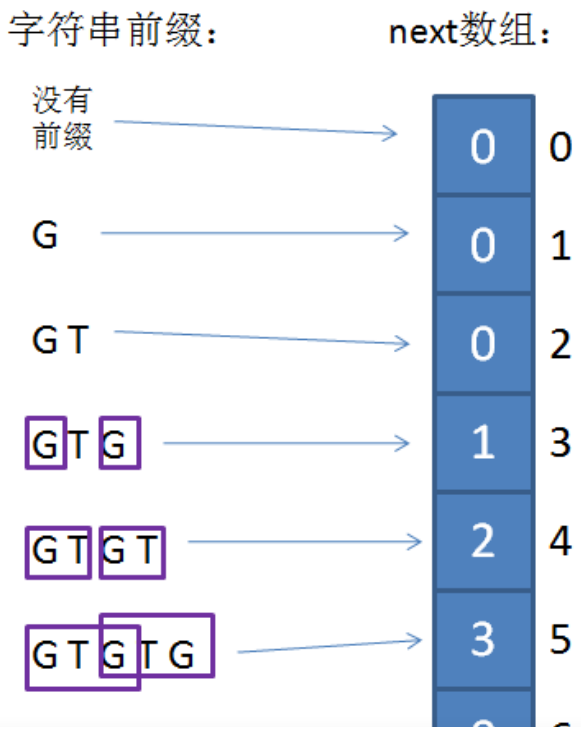

当模式串的第一个字符就和主串不匹配时，并不存在已匹配前缀子串，更不存在最长可匹配前缀子串。这种情况对应的next数组下标是0，next[0]的元素值也是0。

如果已匹配前缀是G、GT、GTGTGC，并不存在最长可匹配前缀子串，所以对应的next数组元素值（next[1]，next[2]，next[6]）同样是0。

GTG的最长可匹配前缀是G，对应数组中的next[3]，元素值是1。

以此类推，

GTGT 对应 next[4]，元素值是2。

GTGTG 对应 next[5]，元素值是3。

有了next数组，我们就可以通过已匹配前缀的下一个位置（坏字符位置），快速寻找到最长可匹配前缀的下一个位置，然后把这两个位置对齐。

比如下面的场景，我们通过坏字符下标5，可以找到next[5]=3，即最长可匹配前缀的下一个位置：

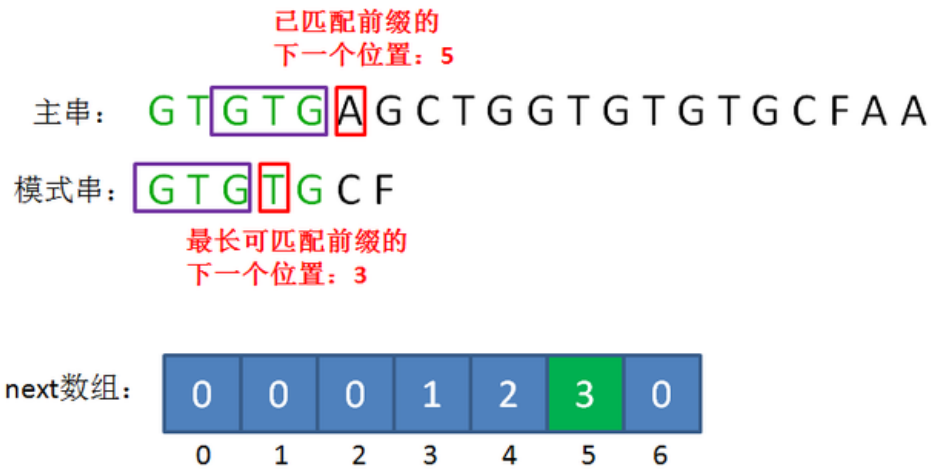

说完了next数组是什么，接下来我们再来思考一下，如何事先生成这个next数组呢?

由于已匹配前缀数组在主串和模式串当中是相同的，所以我们仅仅依据模式串，就足以生成next数组。

最简单的方法是从最长的前缀子串开始，把每一种可能情况都做一次比较。

假设模式串的长度是m，生成next数组所需的最大总比较次数是1+2+3+4+.....+m-2次。

显然，这种方法的效率非常低，如何进行优化呢?

已知next[i]的值，如何推导出next[i+1]呢？让我们来演示一下上述next数组的填充过程：

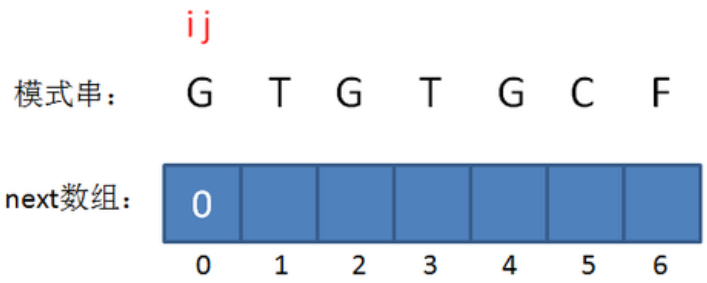

如图所示，我们设置两个变量i和j，其中i表示“已匹配前缀的下一个位置”，也就是待填充的数组下标，j表示“最长可匹配前缀子串的下一个位置”，也就是待填充的数组元素值。

当已匹配前缀不存在的时候，最长可匹配前缀子串当然也不存在，所以i=0，j=0，此时next[0] = 0。

接下来，我们让已匹配前缀子串的长度加1：

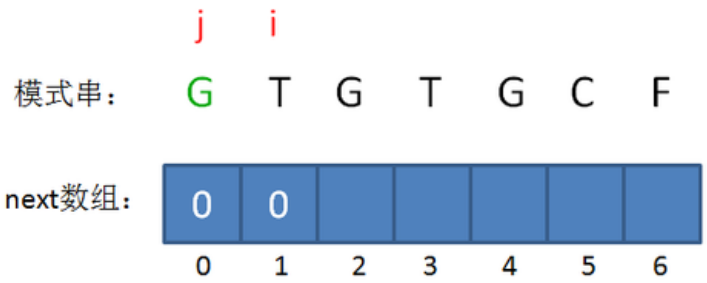

此时的已匹配前缀是G，由于只有一个字符，同样不存在最长可匹配前缀子串，所以i=1，j=0，next[1] = 0。

接下来，我们让已匹配前缀子串的长度继续加1：

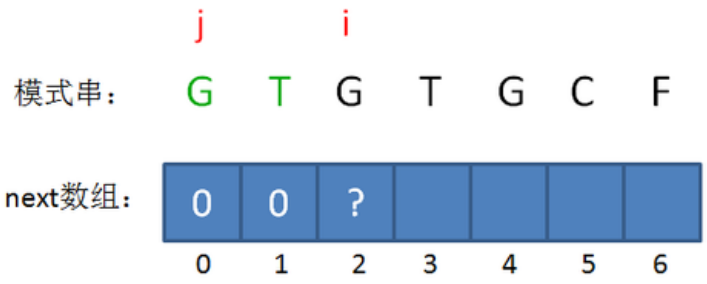

所以当i=2时，j仍然是0，next[2] = 0。

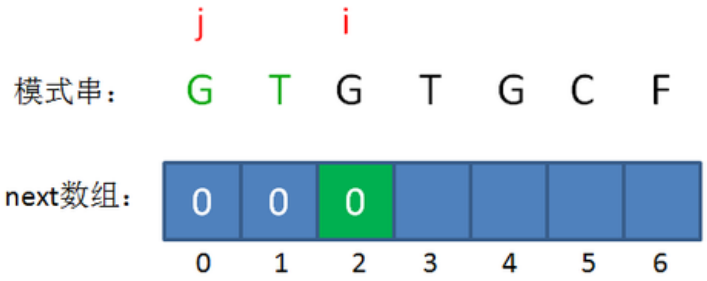

接下来，我们让已匹配前缀子串的长度继续加1：

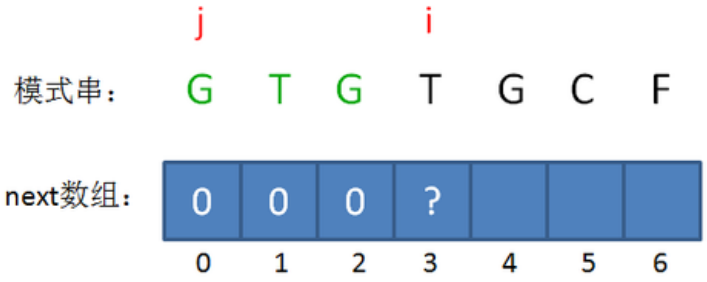

此时的已匹配前缀是GTG，由于模式串当中 pattern[j] = pattern[i-1]，即G=G，最长可匹配前缀子串出现了，是G。

所以当i=3时，j=1，next[3] = next[2]+1 = 1。

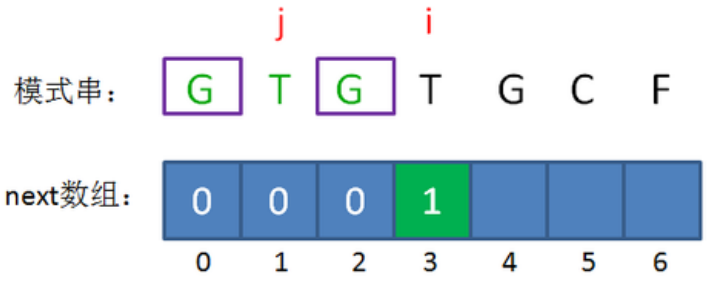

接下来，我们让已匹配前缀子串的长度继续加1：

此时的已匹配前缀是GTGT，由于模式串当中 pattern[j] = pattern[i-1]，即T=T，最长可匹配前缀子串又增加了一位，是GT。

所以当i=4时，j=2，next[4] = next[3]+1 = 2。

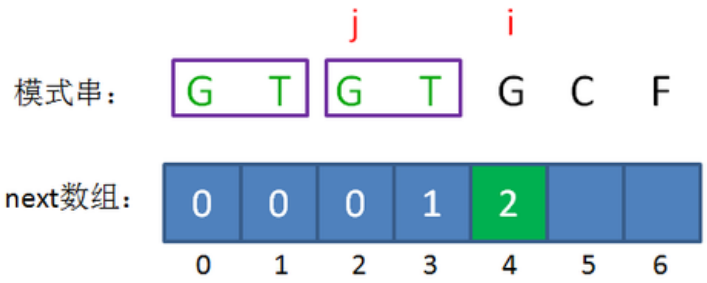

接下来，我们让已匹配前缀子串的长度继续加1：

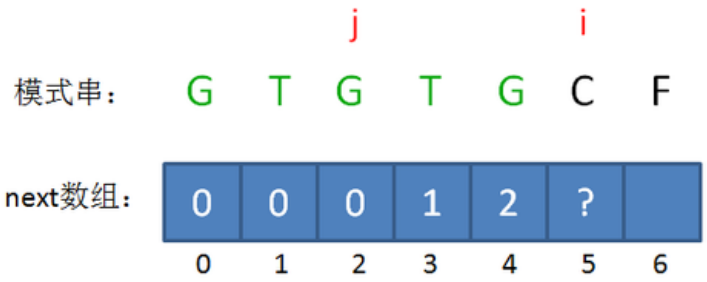

此时的已匹配前缀是GTGTG，由于模式串当中 pattern[j] = pattern[i-1]，即G=G，最长可匹配前缀子串又增加了一位，是GTG。

所以当i=5时，j=3，next[5] = next[4]+1 = 3。

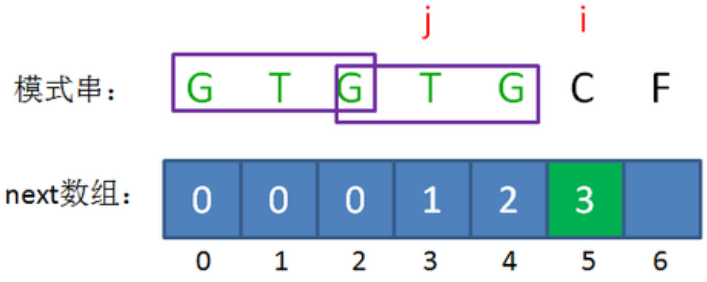

接下来，我们让已匹配前缀子串的长度继续加1：

此时的已匹配前缀是GTGTGC，这时候需要注意了，模式串当中 pattern[j] ！ = pattern[i-1]，即T != C，这时候该怎么办呢?

这时候，我们已经无法从next[5]的值来推导出next[6]，而字符C的前面又有两段重复的子串“GTG”。那么，我们能不能把问题转化一下?

或许听起来有些绕：我们可以把计算“GTGTGC”最长可匹配前缀子串的问题，转化成计算“GTGC”最长可匹配前缀子串的问题。

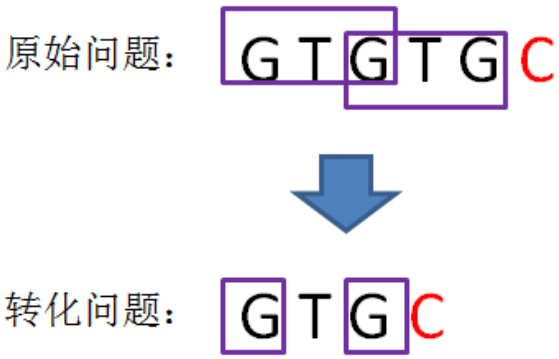

这样的问题转化，也就相当于把变量j回溯到了next[j]，也就是j=1的局面（i值不变）：

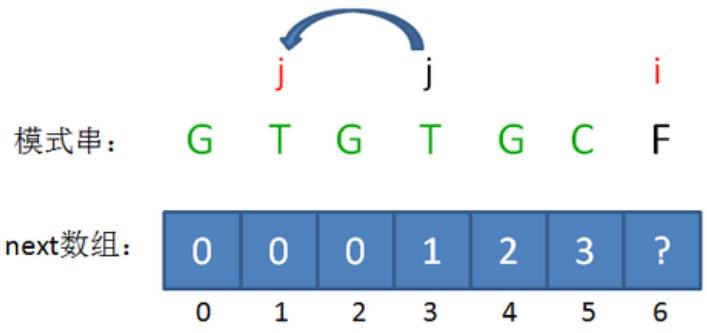

回溯后，情况仍然是 pattern[j] ！ = pattern[i-1]，即T！=C。那么我们可以把问题继续进行转化：

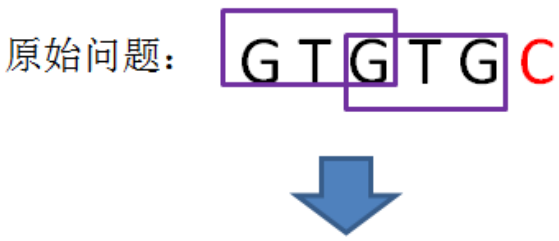

问题再次的转化，相当于再一次把变量j回溯到了next[j]，也就是j=0的局面：

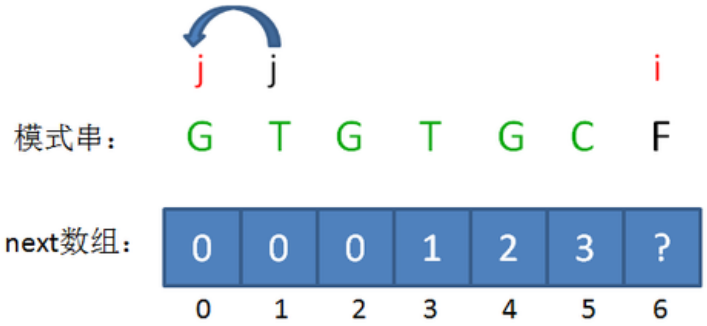

回溯后，情况仍然是 pattern[j] ！ = pattern[i-1]，即G！=C。j已经不能再次回溯了，所以我们得出结论：i=6时，j=0，next[6] = 0。

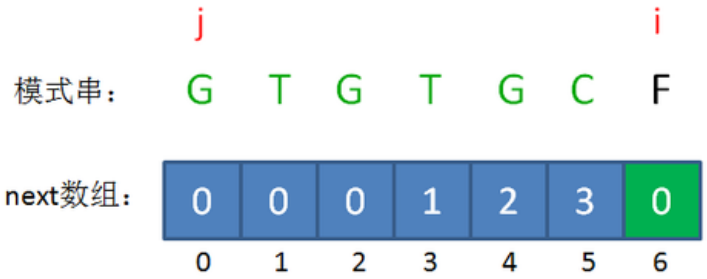

以上就是next数组元素的推导过程。

我的天呐，next 数组的推导过程实在太烧脑了.....

1. 对模式串预处理，生成next数组

2. 进入主循环，遍历主串

2.1. 比较主串和模式串的字符

2.2. 如果发现坏字符，查询next数组，得到匹配前缀所对应的最长可匹配前缀子串，移动模式串到对应位置

2.3.如果当前字符匹配，继续循环

KMP算法的具体实现


```
1. // KMP算法主体逻辑。str是主串，pattern是模式串
   publicstaticintkmp(String str, String pattern) {
   //预处理，生成next数组
   int[] next = getNexts(pattern);
   int j = 0;
   //主循环，遍历主串字符
   for (int i = 0; i < str.length(); i++) {
   while (j > 0 && str.charAt(i) != pattern.charAt(j)) {
   //遇到坏字符时，查询next数组并改变模式串的起点
   j = next[j];
   }
   if (str.charAt(i) == pattern.charAt(j)) {
   j++;
   }
   if (j == pattern.length()) {
   //匹配成功，返回下标
   return i - pattern.length() + 1;
   }
   }
   return-1;
   }
   // 生成Next数组
   privatestaticint[] getNexts(String pattern) {
   int[] next = newint[pattern.length()];
   int j = 0;
   for (int i=2; i<pattern.length(); i++) {
```

```
}
if (pattern.charAt(j) == pattern.charAt(i-1)) {
j++;
}
next[i] = j;
}
return next;
}
publicstaticvoidmain(String[] args) {
String str = "ATGTGAGCTGGTGTGTGCFAA";
String pattern = "GTGTGCF";
int index = kmp(str, pattern);
System.out.println("首次出现位置：" + index);
}
```

我知道啦！首先空间复杂度很好计算，KMP 算法唯一的额外空间是 next 数组，假设模式串长度是 m，那么算法的空间复杂度就是 O(m)。

至于时间复杂度，KMP 算法包括两步，第一步生成 next 数组，时间复杂度可以估算为 O(m)；第二步的主循环是对主串的遍历，时间复杂度可以估算为 O（n）

因此，KMP 算法的整体时间复杂度是 O(m+n)，其中 m 是模式串长度，n 是主串长度。

【End】

阿里大牛：
华先胜、丁险峰直播分享！

今晚7点
，阿里巴巴集团
副总裁华先胜
——《
人工智能：
是风、是云，还是雨?
》

面向开发者详解视觉智能技术规模化落地的挑战；面向企业详述如何通过核心AI技术、产品化 及平台化实现客户价值并构建壁垒?

发表评论

发表神评妙论

幻x星

谢谢，终于懂了

2020-06-28 回复 7

屠龙勇士0K

学会了，谢谢!

2020-02-28 回复 5

宇宙无敌观察者

面试的是基因组测序比对程序员吗

2020-02-28 回复 2

没有更多啦